表 1: 检测性能对比—frozen

$_{v}$1.0.0(86)

工具	ITT-TPR	PP-TPR	FPR	F1	MCC	检测机制
MtAgentLens (eBPF)	**0.9851**	1.0000	0.0000	0.9925	0.9674	eBPF + PBC 门控 + Observer
Agent Sentinel	**0.358**	—	0.316	0.495	0.053	LLM 文本分析
LLM Guard	**0.687**	—	0.789	0.719	−0.110	DeBERTa-v3 关键词
Meta Prompt Guard	**0.149**	—	0.105	0.253	−0.128	Prompt-Guard-86M

表 2: 按攻击类型分解—TPR / FPR

攻击类型	**MtAgentLens**	**Agent Sentinel**	**LLM Guard**	**Meta Prompt Guard**
A —直接注入 (n=10)	**1.0000**	0.900	0.500	0.000
B —间接攻击 (n=34)	**0.9706**	0.353	0.853	0.235
C —多 Agent (n=23)	**1.0000**	0.130	0.522	0.087
良性 FPR (n=19)	**0.0000**	0.316	0.789	0.105

表 3: 消融实验主指标

层	能力	AUROC	AUPRC	Cohen_d	Brier↓	ECE↓
L0	Rules + CUSUM	**0.5075**	0.9994	0.1728	0.1757	0.0647
L1	+ PBC Detection	**0.9717**	0.9939	5.1805	0.0692	0.1610
L2	+ Evidence + Identity	**0.9717**	0.9936	6.6620	0.0393	0.1023
L3	+ Observer (Full System)	**0.9851**	0.9967	7.0363	0.0372	0.1053

表 4: 层间边际贡献—ΔAUROC 与统计显著性

转移	**加入的组件**	**ΔAUROC**	**DeLong z**	**p-value**	**ΔCohen_d**	**ΔBrier**
L0 → L1	+ PBC Detection	+0.4643	22.026	0.0000	+5.0077	−0.1066
L1 → L2	+ Evidence + Identity	+0.0000	0.000	1.0000 —	+1.4815	−0.0299
L2 → L3	+ Observer (Full System)	+0.0134	0.997	0.3189 —	+0.3744	−0.0021

表 5: 固定阈值 (0.15) 二分类混淆矩阵

层	能力	TP	FP	FN	TN	TPR	FPR	F1	MCC
L0	Rules + CUSUM	67	19	0	0	1.0000	1.0000	0.8758	0.0000
L1	+ PBC Detection	65	0	2	19	0.9701	0.0000	0.9848	0.9369
L2	+ Evidence + Identity	65	0	2	19	0.9701	0.0000	0.9848	0.9369
L3	+ Observer (Full System)	66	0	1	19	0.9851	0.0000	0.9925	0.9674

表 6: 按攻击类型的 AUROC

层	Type A (n=10)	Type B (n=34)	Type C (n=23)	总体
L0	0.5000	0.5147	0.5000	0.5075
L1	1.0000	0.9443	1.0000	0.9717
L2	1.0000	0.9443	1.0000	0.9717
L3	1.0000	0.9706	1.0000	0.9851

表 7: 分数分布（分位数）

层	攻击 P25	攻击 P50	攻击 P75	良性 P25	良性 P50	良性 P75
L0	0.8411	0.8411	0.8411	0.8411	0.8411	0.8411
L1	0.8109	0.8854	0.9105	0.0000	0.0000	0.0000
L2	0.8619	0.9310	0.9599	0.0000	0.0000	0.0000
L3	0.8604	0.9279	0.9572	0.0000	0.0000	0.0000

表 8: 分数分布细节

层	攻击 μ	攻击 σ	良性 μ	良性 σ	均值差	Cohen_d
L0	0.8425	0.0110	0.8411	0.0000	0.0013	0.1728
L1	0.7926	0.2155	0.0026	0.0085	0.7900	5.1805
L2	0.8673	0.1822	0.0050	0.0180	0.8623	6.6620
L3	0.8634	0.1716	0.0050	0.0180	0.8584	7.0363

表 9: Observer LLM 调用统计

指标	**数值**
触发场景数	63 / 86
总调用次数	312
Failed (调用失败)	297 次 (95
Unsafe (推高分数)	8 次 (3
Safe (压低分数)	4 次 (1
Uncertain (无调整)	3 次 (1
方向正确率	1/4
良性误触发	0

表 10: Observer 对整体指标的影响 (L2 $\rightarrow$ $L3$)

指标	**L2 (无 Observer)**	**L3 (有 Observer)**	**Δ**
AUROC	0.9717	0.9851	+0.0134
Cohen_d	6.6620	7.0363	+0.3743
Brier↓	0.0393	0.0372	−0.0021
ECE↓	0.1023	0.1053	+0.0030
攻击均值	0.8673	0.8634	−0.0039
良性均值	0.0050	0.0050	+0.0000

表 11: InjecAgent 外部基准—2108 攻击 + 149 短良性 + 19 长良性

工具	TPR	FPR(短)	FPR(长)	F1	MCC	LLM 调用
MtAgentLens	**0.8605**	0.0134	0.0000	0.9250	0.5305	777
Agent Sentinel	**0.9900**	0.0000	0.3160	0.9950	0.9315	2257
LLM Guard	**0.1509**	0.0000	0.789	0.2622	0.1077	0 (本地)
Meta Prompt Guard	**1.0000**	1.0000	0.105	1.0000	0.0000	0 (本地)