表 1: 检测性能对比—frozen

$_{v}$1.0.0(86)

工具	ITT-TPR	PP-TPR	FPR	F1	MCC	检测机制
MtAgentPrism (eBPF)	**0.8955**	0.9836	0.0000	0.9449	0.8090	eBPF + PBC 门控 + Observer
Agent Sentinel	**0.358**	—	0.316	0.495	0.053	LLM 文本分析
LLM Guard	**0.687**	—	0.789	0.719	−0.110	DeBERTa-v3 关键词
Meta Prompt Guard	**0.149**	—	0.105	0.253	−0.128	Prompt-Guard-86M

表 2: 按攻击类型分解—TPR / FPR

攻击类型	**MtAgentPrism**	**Agent Sentinel**	**LLM Guard**	**Meta Prompt Guard**
A —直接注入 (n=10)	**0.9000**	0.900	0.500	0.000
B —间接攻击 (n=34)	**0.8235**	0.353	0.853	0.235
C —多 Agent (n=23)	**1.0000**	0.130	0.522	0.087
良性 FPR (n=19)	**0.0000**	0.316	0.789	0.105

表 3: 消融实验主指标

层	能力	AUROC	AUPRC	Cohen_d	Brier↓	ECE↓
L0	Rules + CUSUM	**0.7388**	0.9994	1.2545	0.1953	0.2199
L1	+ PBC Detection	**0.9529**	0.9986	3.4641	0.1216	0.1986
L2	+ Evidence + Identity	**0.9623**	0.9908	3.5717	0.1061	0.1395
L3	+ Observer (Full System)	**0.9623**	0.9908	3.7675	0.0968	0.1301

表 4: 层间边际贡献—ΔAUROC 与统计显著性

转移	**加入的组件**	**ΔAUROC**	**DeLong z**	**p-value**	**ΔCohen_d**	**ΔBrier**
L0 → L1	+ PBC Detection	+0.2141	6.939	0.0000	+2.2097	−0.0736
L1 → L2	+ Evidence + Identity	+0.0094	0.677	0.4987 —	+0.1075	−0.0156
L2 → L3	+ Observer (Full System)	−0.0000	-0.000	1.0000 —	+0.1959	−0.0093

表 5: 固定阈值 (0.15) 二分类混淆矩阵

层	能力	TP	FP	FN	TN	TPR	FPR	F1	MCC
L0	Rules + CUSUM	67	19	0	0	1.0000	1.0000	0.8758	0.0000
L1	+ PBC Detection	60	0	7	19	0.8955	0.0000	0.9449	0.8090
L2	+ Evidence + Identity	60	0	7	19	0.8955	0.0000	0.9449	0.8090
L3	+ Observer (Full System)	60	0	7	19	0.8955	0.0000	0.9449	0.8090

表 6: 按攻击类型的 AUROC

层	Type A (n=10)	Type B (n=34)	Type C (n=23)	总体
L0	0.7500	0.7206	0.7609	0.7388
L1	0.9474	0.9226	1.0000	0.9529
L2	0.9842	0.9303	1.0000	0.9623
L3	0.9842	0.9303	1.0000	0.9623

表 7: 分数分布（分位数）

层	攻击 P25	攻击 P50	攻击 P75	良性 P25	良性 P50	良性 P75
L0	0.4601	0.4601	0.7592	0.4601	0.4601	0.4601
L1	0.7649	0.8532	0.9530	0.0000	0.0000	0.0000
L2	0.9101	0.9562	0.9993	0.0000	0.0000	0.0000
L3	0.9075	0.9734	1.0000	0.0000	0.0000	0.0000

表 8: 分数分布细节

层	攻击 μ	攻击 σ	良性 μ	良性 σ	均值差	Cohen_d
L0	0.5873	0.1434	0.4601	0.0000	0.1272	1.2545
L1	0.7451	0.3042	0.0000	0.0000	0.7451	3.4641
L2	0.8209	0.3251	0.0000	0.0000	0.8209	3.5717
L3	0.8331	0.3127	0.0000	0.0000	0.8331	3.7675

表 9: Observer LLM 调用统计

指标	**数值**
触发场景数	34 / 86
总调用次数	54
Unsafe (推高分数)	32 次 (59
Safe (压低分数)	16 次 (30
Uncertain (无调整)	4 次 (7
Failed (调用失败)	2 次 (4
方向正确率	13/19
良性误触发	0

表 10: Observer 对整体指标的影响 (L2 $\rightarrow$ $L3$)

指标	**L2 (无 Observer)**	**L3 (有 Observer)**	**Δ**
AUROC	0.9623	0.9623	+0.0000
Cohen_d	3.5717	3.7675	+0.1958
Brier↓	0.1061	0.0968	−0.0093
ECE↓	0.1395	0.1301	−0.0094
攻击均值	0.8209	0.8331	+0.0122
良性均值	0.0000	0.0000	+0.0000

表 11: InjecAgent 外部基准—2108 攻击 + 149 短良性 + 19 长良性

工具	TPR	FPR(短)	FPR(长)	F1	MCC	LLM 调用
MtAgentPrism	**0.8605**	0.0134	0.0000	0.9250	0.5305	777
Agent Sentinel	**0.9900**	0.0000	0.3160	0.9950	0.9315	2257
LLM Guard	**0.1509**	0.0000	0.789	0.2622	0.1077	0 (本地)
Meta Prompt Guard	**1.0000**	1.0000	0.105	1.0000	0.0000	0 (本地)