表 1: 按攻击类型分解—TPR / FPR

攻击类型	**MtAgentLens**	**Agent Sentinel**	**LLM Guard**	**Meta Prompt Guard**
A —直接注入 (n=10)	**1.0000**	0.900	0.500	0.000
B —间接攻击 (n=34)	**0.9706**	0.353	0.853	0.235
C —多 Agent (n=23)	**1.0000**	0.130	0.522	0.087
良性 FPR (n=19)	**0.0000**	0.316	0.789	0.105