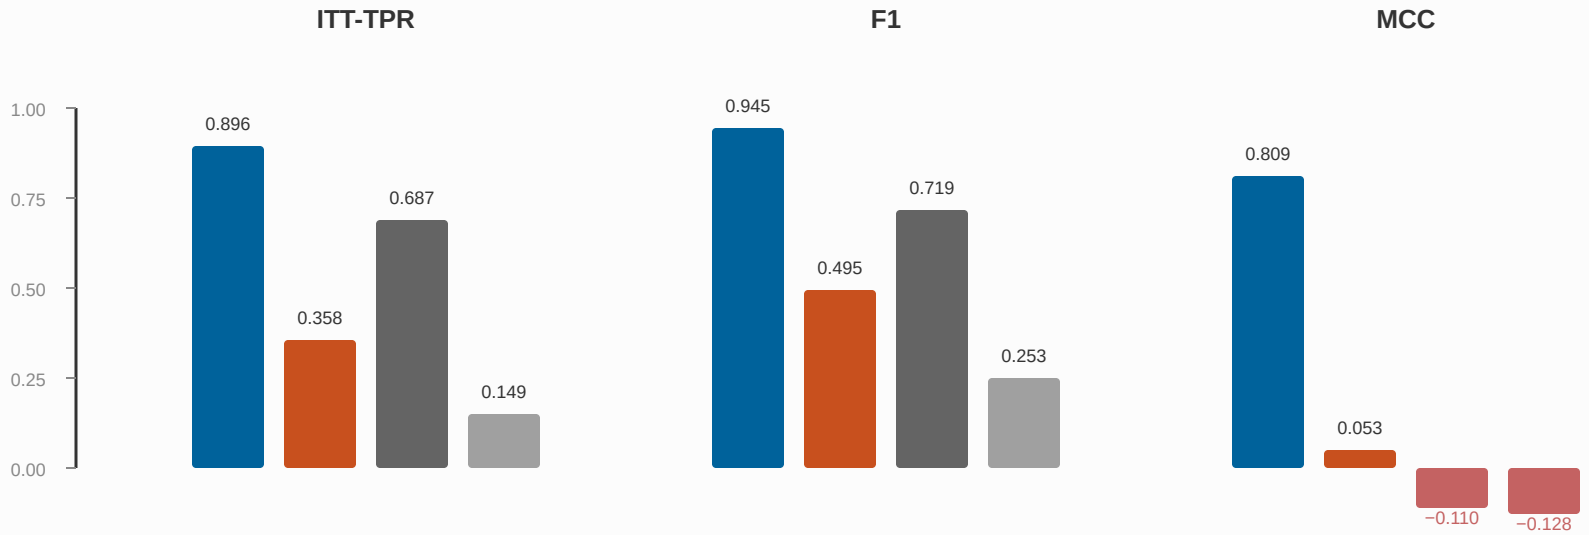


按攻击类型 TPR 与检测差距性质

攻击类型	MtAgentLens	Agent Sentinel	LLM Guard	Meta Prompt Guard	差距性质
A — 直接注入 (n=10)	**0.900**	0.900	0.500	0.000	结构性
B — 间接注入 (n=34)	**0.824**	0.353	0.853[1]	0.235	结构性
C — 多Agent (n=23)	**1.000**	0.130	0.522	0.087	**原理性 — 无恶意文本**

[1] LLM Guard Type B TPR = 0.853 以 FPR = 0.789 为代价, 实际不可用。

Type C 的差距是原理性的: prompt基线分析孤立的prompt文本, 而多Agent攻击中无任何单个prompt是恶意的。

MtAgentLens Agent Sentinel LLM Guard Meta Prompt Guard