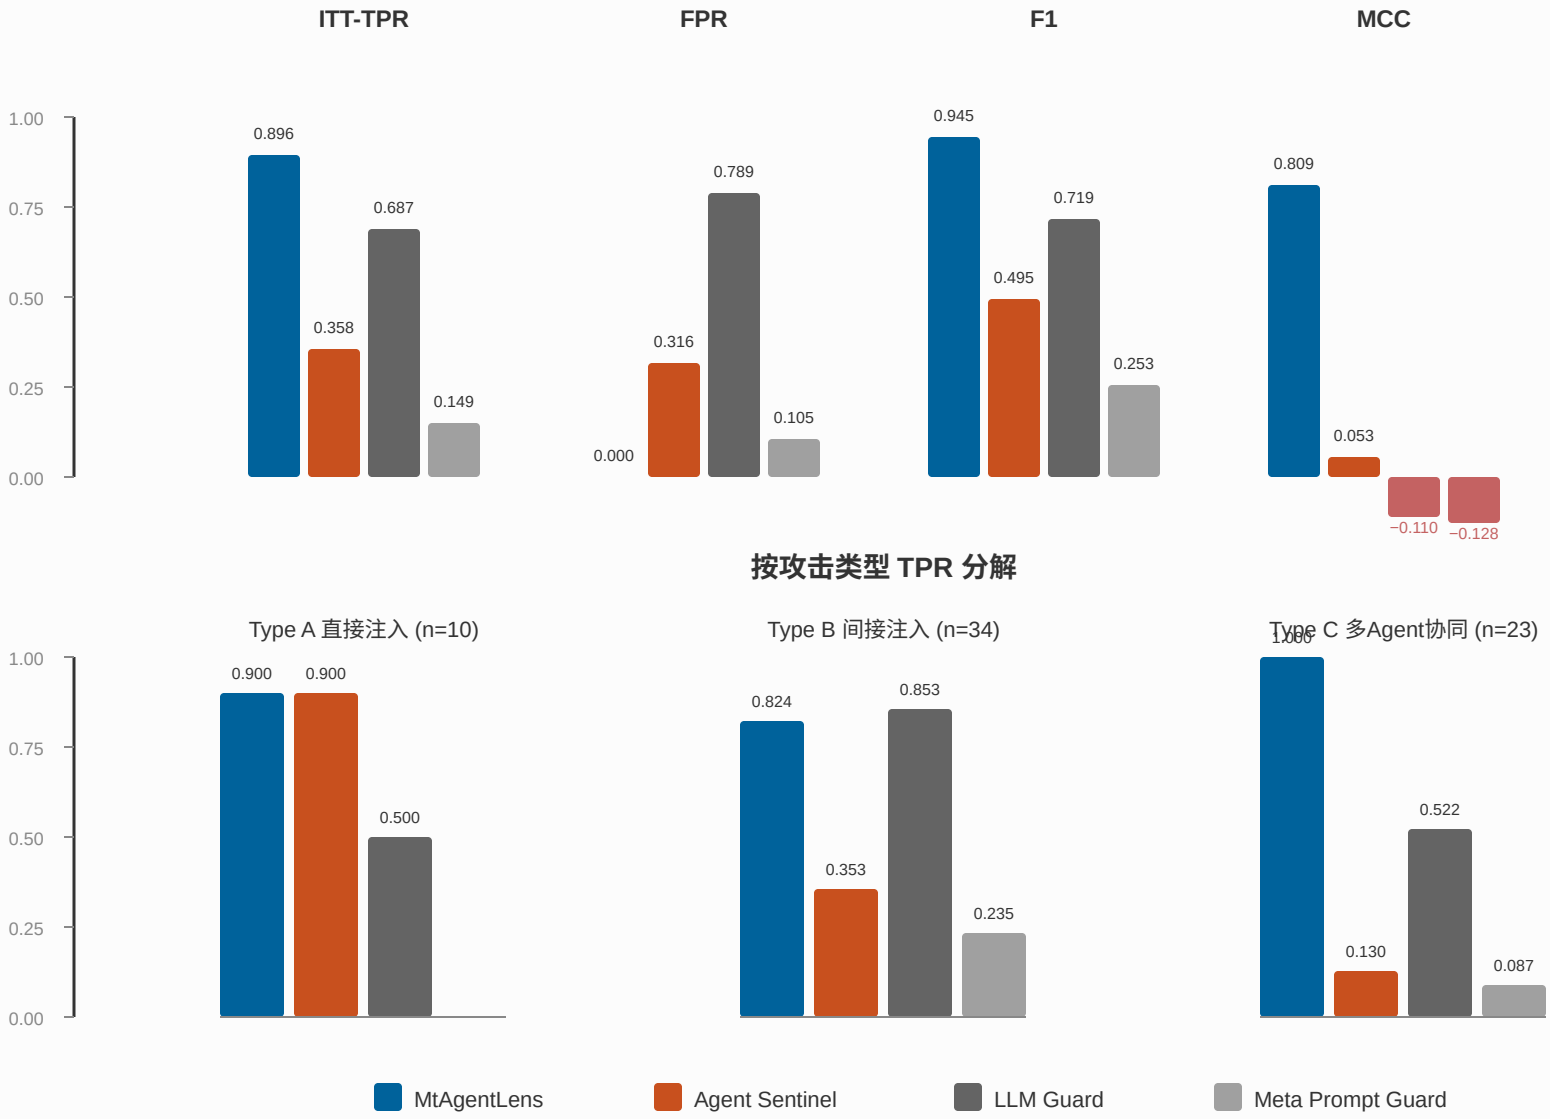


核心发现: Type C 多Agent场景中, prompt级工具原理上失效 (无恶意文本), MtAgentLens 是唯一有效检测方案 (TPR=1.000)

McNemar 配对检验 (Yates 校正): MtAgentLens vs 所有基线 $p < 0.001$ ($b=34,48,50$; 所有 $c=0$)