论文编号：ry029

论文标题：基于 eBPF 的多智能体运行时安全监测与根因定位方法

尊敬的编辑及审稿专家：

感谢编辑及各位专家对稿件的审阅和建议。各项意见的回应及具体修改位置如下。

专家 1 审稿意见：修改及说明

1）第 3.5 节及算法 3 采用 0.15 与 0.70 划分三区，灰色区由 Observer 仲裁；第 6.1.3 节又以最终分数 0.399 高于 0.15 解释攻击判定。建议明确中间分数、校准后分数和最终标签之间的关系，说明 Observer 的 Unsafe、Safe、Uncertain 及调用失败分别如何转化为最终结果。

对该条意见的修改说明：

这条意见的核心是区分评分流水线、阈值路由和最终标签，避免把中间分数直接当作攻击判定依据。修订稿已按“六维评分—基础分数—Observer/规则判定—最终标签”的顺序重写第 3.5 节、算法 3 和第 6.1.4 节案例，并逐项说明 Observer 返回值和调用失败时的处理。

①针对“第 6.1.3 节以 0.399 高于 0.15 解释攻击判定”的意见。

原稿把旧版离线评分链中的 0.399 用于解释当前案例，并以“高于 0.15”作为攻击依据。修订稿已删除这段旧换算，明确 0.15 和 0.70 是基础分数的路由边界：0.15 以下直接进入 Safe，0.70 以上直接进入 Unsafe，介于两者之间才进入 Observer 仲裁；因此该案例的 Unsafe 标签来自 Observer 裁决和强规则证据，而不是由 0.399 高于 0.15 推出。图 5 同步改为展示传播拓扑和判定流程。

②针对“明确中间分数、校准后分数和最终标签之间的关系”的意见。

当前冻结评估的分数关系已统一为：六维子分数先按活跃维度加权融合，再经 sigmoid 映射和 PBC 门控得到基础分数；基础分数只负责决定路由，不直接等同于最终标签。基础分数低于 0.15 时输出 Safe 路由，高于 0.70 时输出 Unsafe 路由，0.15—0.70 之间调用 Observer。修订稿删除旧版 OWA 和旧门控参数的混用，因而中间分数、校准/门控后的基础分数和最终标签在正文中各有明确含义。

③针对“说明 Observer 不同返回及调用失败如何转化为最终结果”的意见。

Observer 返回 Unsafe 时最终标签为攻击，返回 Safe 时为安全，返回 Uncertain 时保留为待复核；调用失败则记录失败状态，并按基础分数回退到同一三区规则（高于 0.70 为 Unsafe，0.15—0.70 为 Uncertain，其余为 Safe）。已确认的强规则违规保留 Unsafe 判定。表格和二元评估均以最终 Unsafe 作为告警，Uncertain 单独统计，因此审稿意见所列的四种情况均已落实到最终输出规则。

修改位置：第 3.5 节“L3：多信号融合监测引擎”、**算法 3**；第 6.1.4 节“**责任链分析**与根因**主体**定位”、图 5。

表 1 判定依据的修改前后对照

位置	文字与判定依据（第 3.5、6.1.4 节）
修改前	……、最终 0.399，高于阈值 0.15。
修改后	基础分数在 0.15—0.70 之间时进入仲裁；最终标签结合 Observer 裁决与强规则证据确定，不以仲裁后分数高于 0.15 为攻击依据。旧 0.399 换算已从正文和图 5 移除。

2）算法 1 依赖进程、TLS 会话和对话标识融合身份，但不同智能体共用进程、连接复用或并发执行时可能发生错误合并。建议明确子智能体边界的识别条件，并量化身份归属与根因定位准确率。现有案例中的链深和图规模能够说明回溯能力，但尚不足以证明定位结果正确。

对该条意见的修改说明：

这条意见包含两个可检验问题：身份解析是否能正确划分子智能体，以及责任链得到的根因主体排序是否准确。修订稿分别增加五种身份视图的量化评估和 16 个多智能体攻击场景的根因智能体定位实验，并把评估分母、参考标签和结果指标写入第 6.1.3、6.1.4 节。

①针对“明确子智能体边界并量化身份归属”的意见。

第 3.4.2 节明确了身份归属条件：具有独立 TLS 会话且满足智能体进程识别条件的子进程保留独立身份；无独立会话的工具子进程继承父身份；证据不足时记为 unknown。第 6.1.3 节在 30 个场景抽取 1,800 个单元，以 1,675 个参考已知单元比较五种身份视图，其中包含同一进程下父 Agent 与子 Agent 的身份区分情形。最终融合视图 C4 覆盖 39.0%，已赋值子集 F1 为 1.000、全参考 F1 为 0.280、错误合并为 0；覆盖率较高的 C2 视图覆盖 74.2%，全参考 F1 为 0.712。由此可见，方法在有身份证据的单元上能够准确分区，并通过保守赋值避免错误合并；实验已经对身份解析效果作出量化验证，并说明了覆盖率与完整参考集得分之间的取舍。

②针对“量化根因定位准确率，而非仅以链深和图规模说明回溯能力”的意见。

根因智能体定位在 16 个实际执行且存在攻击效应的多智能体攻击上评估，其中 7 个 Type B、9 个 Type C，每个场景含 3 个候选主体。本文采用的出网终态排序在 RootAgent@1 上命中 11/16（0.688），RootAgent@2 命中 14/16（0.875），MRR 为 0.823；9 种排序规则的完整结果见表 8，本文方案的首位命中数比仅告警主体策略多 5 例，比最大活跃策略多 2 例。修订稿通过五种身份视图评估身份归属，并在上述 16 个场景上量化评估根因智能体定位，为责任链溯源中的根因主体定位提供了实验依据，也为进一步评估入口事件和有序责任链定位打下基础；后续将继续完善全链路定位评估。

修改位置：第 3.4.2 节“身份解析与因果链追踪”**、算法 1；第 6.1.3 节“身份解析”（图 4）；第 6.1.4 节（表 8 及其后分析）**。

> 3）文章已说明 AgentSentinel 仅复现审计提示流程，且基线与本文方法的输入信息不同，因此当前结果主要支持观测信息的增量价值。建议补充更接近的运行时基线或完整部署对比，并明确 InjecAgent 是否实际执行、如何产生事件流、2,108 个样本及 149 个良性样本的构造方式。

对该条意见的修改说明：

这条意见要求补充更接近的应用层基线，并说明 InjecAgent 文本实验到底评估了什么。修订稿加入接收完整应用轨迹的 R-Judge，补齐 InjecAgent 样本组成、执行方式和文本模式结果，同时删除容易把不同输入条件下的数字直接横向比较的表述。

①针对“补充更接近的运行时基线或完整部署对比”的意见。

第 5.2 节和表 6 加入 R-Judge 作为最接近的应用层定量参照：它接收任务、模型输出、工具调用及返回组成的应用轨迹。93 条轨迹中 91 条存在字段级截断；在执行集上，MtAgentLens 的 TPR/F1 为 0.793/0.852，R-Judge 为 0.552/0.696，R-Judge 的 FPR 为 0.029，MtAgentLens 为 0.057，二元差异经 Holm 校正后 p=0.212。Agent Sentinel-style 只复现论文中可获得的任务文本审计提示和结构化输出流程，结果不被表述为完整部署系统的结果。

②针对“InjecAgent 是否实际执行、事件流如何产生及样本如何构成”的意见。

第 6.3 节明确，2,108 个攻击样本来自四个测试文件（510、544、510、544），149 个短格式良性样本由 99 个控制样本和 50 个补充样本组成。该数据以文本记录评估，未在操作系统中执行，因此不产生 eBPF 事件流；MtAgentLens 在这里运行的是规则引擎与 Observer 的文本模式。统一文本条件下，MtAgentLens 的 TPR/F1 为 0.861/0.925，Agent Sentinel-style 为 0.990/0.995。该实验回答的是弱操作系统信号下的文本模式表现，不把它当作完整运行时部署验证。

③针对“当前比较可能混淆观测层级与信息量”的意见。

为避免把“观测层级”和“输入信息量”混为一个因素，修订稿删除摘要、引言、讨论和结论中的旧版“1.000 对 0.087—0.522”比较，改用 R-Judge 提供应用轨迹条件下的定量参照，并用能力矩阵说明 AgentSight、GUARDIAN、BlindGuard 和 MAStitch 的观测对象、分析单元及输出。由此，论文只比较各方法在其实际输入条件下的结果，不再把差异单独归因于操作系统观测或算法本身。

修改位置：摘要；第 5.2 节“基线系统”；第 6.1.1 节（表 6）；第 6.3 节**（表 10）**；第 7.2 节。

> 4）表 11 中 Meta Prompt Guard 的 TPR 和 FPR_short 均为 1.000，但 F1 也列为 1.000。另外，应说明开发数据与冻结测试场景的隔离关系，并补充与攻击场景行为规模相近的困难良性任务，以排除任务长度和 PBC 数量带来的混杂影响。

对该条意见的修改说明：

这条意见涉及指标计算、参数确定和困难良性覆盖三件事。修订稿将良性场景由原来的 19 个扩展到 35 个，新增 16 个场景；其中 7 个是新增困难良性任务，9 个是重新审查后归为良性的历史攻击设计。同时更正外部基线指标，写明冻结前定参协议，并补充参数敏感性和行为规模对照。

①针对“Meta Prompt Guard 的 F1 与 TPR、FPR_short 同为 1.000”的意见。

Meta Prompt Guard 将 2,108 个攻击样本和 149 个良性样本全部判为攻击，按 2,257 个样本合并计算时精确率为 0.934、F1 为 0.966，原表中的 1.000 已更正；由于预测类别单一，MCC 不定义。逐样本文件计算的 LLM Guard 检出 320 个攻击、误报 1 个良性，表 10 及正文同步改为 TPR 0.152、F1 0.263、FPR_short 0.007、MCC 0.103。各方法的 F1 和 MCC 均统一在 2,257 个样本上计算。

②针对“开发数据与冻结测试场景的隔离关系”的意见。

阈值、权重和门控参数在 93 场景基准冻结前确定，冻结后未依据该基准结果调整；因此修订稿明确说明评估场景不是独立留出测试集。为检验结果是否依赖单点参数，第 6.2.2 节补充 8,103 组阈值组合、单维权重扰动、门控扫描和 1,000 次联合采样，并固定已记录的 Observer 结果与强规则判定。敏感性结果支持部署点附近的 F1 稳定性，但不被表述为独立测试集验证。

③针对“补充与攻击场景行为规模相近的困难良性任务”的意见。

困难良性覆盖已具体扩展，而不是只在讨论中声明。35 个良性场景由 26 个原生良性任务和 9 个重新审查后归为良性的历史攻击设计组成；在新增的困难任务中，包含凭据轮换、环境示例审查、账户/组审计、重负载构建、known_hosts 审计、passwd 审计和 SSH 配置审计等会访问敏感配置或产生较多系统活动的任务。9 个重审场景还覆盖三站式多智能体交接、DNS/TCP 或回环端点通信、主机信息与配置收集以及受控资源负载。第 7.1 节进一步给出 PBC 分布和仅活动量基线，因此修订稿已用高活动量和敏感访问的良性任务检验误报；未将这些任务写成每个攻击均已一一配对的规模匹配实验。

修改位置：第 **5.1** 节；第 6.2.2 节“参数敏感性”（图 7）；第 **6.3 节（表 10 及正文）；**第 **7.1**、**7.3** 节。

> 5）218 ns 探针延迟和采集器 RSS 不能单独代表完整系统成本，建议说明是否计入责任图维护、Observer 调用及外部模型费用，并报告不同并发量下的事件丢失率、告警延迟和内存增长。表 12 将 218 ns 与 1～5 ms 握手比较得出占比小于 0.005%，在 1 ms 端约为 0.0218%，也需修正。

对该条意见的修改说明：

针对完整系统成本，修订稿把责任图维护、持久化、Observer 调用和外部模型费用纳入同一张并发实验表，并将探针微基准单独报告。1、4、8、16、32 个并发智能体每档重复 3 次，所有档位完成率均为 100%，受控缺失和持久化缺失均为 0，进程源丢弃均为 0；Observer 调用次数为 2.0—8.3 次，费用上界为 0.005232—0.067886 美元。由此，表 11 给出的是完整系统的受控负载成本；端到端告警时延作为尚未纳入时间戳采样的后续指标单列。

①针对“探针时延和采集器 RSS 不能代表完整系统成本”的意见。

第 6.4 节和表 11 按 1、4、8、16、32 个并发智能体报告完整系统指标，每档重复 3 次。额外 CPU 占用率依次为 2.7%、3.8%、6.1%、11.7%和 30.7%；平均 PSS 依次为 114.4、115.7、116.9、119.4 和 124.8 MiB，峰值 PSS 依次为 114.8、117.0、119.1、124.4 和 134.5 MiB。各档受控缺失、持久化缺失和进程源丢弃均为 0，完成率均为 100%。这些数据直接回答了并发增加时的资源占用、内存变化和事件缺失情况。

②针对“责任图维护、Observer 调用及外部模型费用是否计入”的意见。

表 11 将完整系统成本拆分为数据库与 WAL、trace 文件、Observer 调用和费用上界，并同时报告受控缺失、持久化缺失、进程源丢弃和完成率。数据库+WAL/trace 占用从 1 个智能体时的 1.42/0.38 MiB 增加到 32 个智能体时的 10.08/12.23 MiB；Observer 调用从 2.0 次增加到 8.3 次，费用上界从 0.005232 美元增加到 0.067886 美元。五档实验中的三类缺失均为 0，完成率为 100%，因此责任图维护和外部调用没有被排除在成本统计之外。

③针对“不同并发量下的事件丢失、告警延迟和内存增长”的意见。

原稿把不同 BPF 程序的平均耗时相加为 218 ns，并与 TLS 握手时长相除，混用了探针微基准与端到端业务时延。第 6.4 节改报每次成功 TLS 读写的累计 BPF 执行时间 873.4 ns，并将其与完整系统的 CPU、PSS、持久化和丢失指标分开。事件缺失已在五档并发实验中测量，受控缺失、持久化缺失和进程源丢弃均为 0；告警时延没有配套端到端时间戳，因此不把探针时间替代告警时延。

修改位置：第 6.4 节“RQ4：性能开销”（表 11 **与探针微基准段**）；第 7.2 节“操作系统级可观测性的价值边界与部署策略”。

专家 2 审稿意见：修改及说明

专家 2 的意见以连续文字提出，修订稿按五项具体关切分列回应。

> 1）良性场景仅 19 个，FPR 的 95% CI 上界达 0.176，“零误报”的统计说服力有限。基准、阈值（0.15/0.70）、六维权重、门控参数均由作者团队确定，文中称“依据开发阶段数据确定”，但未说明开发数据与测试集是否独立、规模多大。建议补充更多困难良性样本，尤其是本身会产生大量委派、敏感路径访问和外部网络连接的正常多智能体任务。

对该条意见的修改说明：

这条意见同时质疑良性样本规模、参数是否独立以及困难良性覆盖。修订稿将良性场景由 19 个扩展到 35 个，新增 16 个场景；重新计算 FPR 及置信区间，补充冻结前定参和参数敏感性实验，并把新增困难良性任务的行为类型写入基准说明。

①针对“19 个良性场景及误报率置信区间”的意见。

良性场景由原 19 个增加到 35 个，当前有 2 例 Unsafe 误报，FPR 为 0.057，95% Wilson 区间为[0.016,0.186]。新增的 16 个场景包括 7 个困难良性任务和 9 个重新审查后归为良性的历史攻击设计；正文统一报告 35 个场景上的点估计和区间，不再用原 19 个场景的 0/19 支持“零误报”。另有 21 个场景为 Uncertain，按协议单独统计，不把它们直接并入确定安全。

②针对“参数确定过程及开发数据与测试集是否独立”的意见。

阈值、权重和门控参数在 93 场景基准冻结前确定，冻结后未根据测试结果调整；修订稿明确说明没有另设独立留出测试集，因此不把当前场景称为独立验证。第 6.2.2 节以 8,103 组阈值组合、单维权重和门控扫描、1,000 次联合采样检验参数扰动，结果用于说明部署点附近的稳定性，而不替代独立工作流验证。

③针对“补充含大量委派、敏感访问和网络活动的困难良性任务”的意见。

新增困难良性并非普通低活动任务。26 个原生良性任务中包含 7 个新增困难任务，覆盖凭据轮换、环境文件审查、账户/组与 passwd 审计、重负载构建、known_hosts 和 SSH 配置审计；另外 9 个历史攻击设计经重新审查后归为良性，其中包括三站式多智能体交接、DNS/TCP 或回环通信、主机信息与配置收集及受控磁盘/CPU 负载。这样，35 个良性场景已经覆盖审稿人所关心的委派、敏感访问、网络活动和高行为量情形。第 7.1 节再用 PBC 分布和活动量阈值基线检查其误报表现；这些实验支持“已覆盖困难良性”的结论，但不把所有攻击与良性任务描述成逐项配对。

修改位置：第 5.1 节；第 6.1.1 节（表 6）；第 6.2.2 节（图 7）；第 7**.1、7.3** 节。

> 2）Type C 平均 PBC 为 396.7，远高于 A、B 两类，但没有报告良性场景（特别是多智能体良性场景）的 PBC 分布。D4 取 min(重复次数/50,1)，D6 除以 50，门控中心为 N_PBC=10，这些设计都与行为“量”强相关。需要排除这样一种可能：检测主要是在区分“活动多的任务”和“活动少的任务”，而不是区分恶意与良性。建议给出攻击与良性场景的 PBC 分布对比，以及在 PBC 规模相当的良性多智能体任务上的误报情况。

对该条意见的修改说明：

审稿人担心检测器可能只是把“活动多”当成“恶意”。修订稿用两个直接对照回答：一是按 93 条主结果逐场景比较攻击与良性 PBC 分布，二是只用 PBC 数量建立活动量基线，再与完整判定流程比较。结果表明 PBC 有排序信息，但单独阈值会把大量良性任务误报，完整系统明显降低误报。

①针对“报告攻击与良性场景的 PBC 分布”的意见。

第 7.1 节按与主检测表一致的 93 条结果统计：攻击场景 PBC 中位数、均值和最大值分别为 122.5、466.5 和 3,941，良性场景分别为 28.0、163.3 和 1,765；两组分布存在重叠。旧版 Type C 平均 396.7 来自不同类别参照，已从正文删除。这个分布结果直接说明 PBC 数量不是攻击标签的充分条件。

②针对“D4、D6 和门控与行为量相关”的意见。

表 4 和第 3.5 节明确了各量的分工：D4 是观测计数的归一化量，D6 是证据支持的边界访问和高置信关联记录的归一化聚合，门控以 PBC 数量作为输入。它们都可能携带任务规模信息，因此修订稿用 PBC 分布、单特征基线和完整流程的对照来判断贡献，而不是把任何一个“量”直接等同于恶意性。

③针对“排除检测主要区分活动多少而非恶意与良性”的意见。

PBC 单特征 AUROC 为 0.668；在 29 个执行攻击和 35 个良性场景上，PBC≥10 直接告警的 TPR 为 0.966、FPR 为 0.686，而完整系统 FPR 为 0.057。也就是说，活动量能够帮助排序，但单独按活动量告警会误报大量良性任务；完整系统还利用行为类型、身份、责任图和证据关联，因而检测结果不能归结为“活动多就是攻击”。新增的困难良性场景正用于检验这一点，当前结论是活动量有贡献但不是充分判据。

修改位置：第 **3.5 节（表 4 及门控）；**第 7.1 节“PBC 对 Type C 的作用机制”；第 6.1.1 节（表 6）。

> 3）三个基线只接收提示词文本，而 MtAgentLens 接收完整 OS 事件流并调用 Observer LLM，信息量不对等。作者已说明这一点，但结论中“1.000 vs 0.087～0.522”的对比容易被误读。缺少与同层级或相近思路方法的比较，如 AgentSight（eBPF）、GUARDIAN（时序图）、BlindGuard、MAStitch。AgentSentinel 仅复现了审计提示词，并改用 DeepSeek v4 Pro。建议至少增加一个“文本 + 工具调用日志”的应用层基线，或给基线提供等价的执行轨迹信息，以区分“观测层级”和“信息量”各自的贡献。

对该条意见的修改说明：

这条意见要求同时处理三件事：补充接收应用轨迹的基线、说明同级方法的可比范围、解释 Agent Sentinel-style 的复现边界。修订稿分别加入 R-Judge 定量对照、补充能力矩阵，并明确模型和复现条件，避免把不同输入下的结果当作同一实验。

①针对“增加同层级或相近思路方法比较”的意见。

论文表 1 和本说明表 2 列出 AgentSight、GUARDIAN、BlindGuard、MAStitch 等方法的观测对象、主要信号、分析单元和输出。由于这些方法的任务、输入信号和标注方式不同，直接搬用各自基准数字不能回答“观测层级还是算法造成差异”；因此修订稿不做跨基准排名，同时加入接收完整应用轨迹的 R-Judge 作为定量参照。

表 2　同级方法能力矩阵

方法	观测层级与主要信号	分析单元（跨智能体）	输出
AgentSentinel	应用层：工具调用、任务上下文	单智能体（否）	安全/不安全审计
AgentSight	系统层：eBPF 明文与系统调用	单智能体（否）	可观测性视图，无攻击标签
GUARDIAN	应用层：交互与时序图	多智能体（是）	攻击/良性判定
BlindGuard	应用层：智能体间交互模式	多智能体（是）	传播异常（无监督）
MAStitch	应用层：局部与全局交互图	多智能体系统（是）	威胁判定
MtAgentLens（本文）	系统层：进程/文件/网络/SSL-TLS	多智能体责任图（是）	攻击判定与责任链分析

②针对“Agent Sentinel 仅复现提示词流程并改用 DeepSeek 模型”的意见。

第 5.2 节明确 Agent Sentinel-style 只复现可获得的任务文本审计提示和结构化输出流程，不声称复现其完整沙箱部署；这是因为当前可复现材料不包含完整沙箱的部署和运行条件。模型配置按实际记录采用 DeepSeek Flash，并与其他使用 DeepSeek 的 LLM 审计基线保持一致，以控制模型差异、保证输入流程比较具有可比性。修订稿据此把结论限定为该文本审计流程的表现，不从模型名称推断基线强弱。

修改位置：第 5.2 节；第 6.1.1 节（表 6）

> 4）根因定位是标题中的核心能力之一，但目前只有 3 个 Type C 案例的定性展示和深度统计，没有在全部 23 个 Type C 场景上的定量指标（如根因智能体/入口定位的准确率、Top-k 命中率）。身份解析（并查集融合）的正确率同样没有单独评估。建议补充上述定量结果。

对该条意见的修改说明：

这条意见要求给出两个独立结果：身份解析的正确性，以及根因智能体定位的定量准确性。修订稿在第 6.1.3 节报告五种身份视图的覆盖率、F1 和错误结构，在第 6.1.4 节报告 16 个多智能体攻击场景的 RootAgent@1、@2 和 MRR，并明确 23 个旧 Type C 场景与当前评估分母不是同一集合。

①针对“23 个 Type C 场景上的根因定位定量指标”的意见。

当前根因智能体定位分母为 16 个实际执行且存在攻击效应的多智能体攻击，其中 7 个 Type B、9 个 Type C，每个场景含 3 个候选主体；另有 11 个单智能体有效运行因候选主体唯一只作覆盖确认。本文采用的出网终态排序命中 RootAgent@1 为 0.688（11/16）、RootAgent@2 为 0.875（14/16），MRR 为 0.823。这正是新增定量实验相对于原来 3 个定性案例的补充。

②针对“身份解析的正确率也应单独评估”的意见。

身份解析的量化结果见专家 1 第 2 条。第 6.1.3 节在 30 个场景、1,800 个单元上完成五种视图评估：C2 覆盖 74.2%，全参考 F1 为 0.712；最终融合视图 C4 覆盖 39.0%，已赋值子集 F1 为 1.000、全参考 F1 为 0.280、错误合并为 0。该结果单独回答了身份解析正确率问题，并说明系统以保守赋值换取主体边界的可靠性；其输出随后作为责任图和根因智能体排序的输入。

修改位置：第 **6.1.3 节“身份解析”（图 4）；**第 6.1.4 节**“责任链分析与根因主体定位”**（表 8）。

> 5）L0→L1 同时引入 eBPF 与 PBC，无法区分两者各自的贡献。L1→L2（责任图）的 AUROC 增益不显著（p=0.499），L2→L3 的 AUROC 不变，说明责任图和 Observer 对检测本身贡献有限。这与文中对责任图的重视程度存在落差。建议拆分 eBPF 与 PBC，并对六维评分做逐维 leave-one-out 消融。

对该条意见的修改说明：

这条意见关注组件贡献能否区分，以及评分参数变化是否会影响结论。修订稿分别以五层配置比较组件逐步加入时的排序表现，并通过阈值、权重、门控和联合采样检验参数变化下的结果稳定性；两类分析分别对应组件贡献与参数敏感性。

①针对“L0 到 L1 同时引入 eBPF 与 PBC，无法区分各自贡献”的意见。

第 6.2.1 节比较 L0 原始动作量、L0.5 加责任图、L1 加 PBC/模式、L2 加身份/证据和 L3 完整分数。现有实现中，eBPF 是 PBC 的事件来源，二者不能依据现有记录作正交拆分；修订稿因此报告可复现的递进配置结果，并明确其评估范围。该分析比较增加责任图和边界信号后的结果变化，不将其解释为 eBPF 与 PBC 各自独立贡献的估计。

②针对“责任图和 Observer 对检测贡献有限，与论文强调程度不一致”的意见。

责任图阶段使 AUROC 由 0.590 升至 0.677，AUPRC 由 0.651 升至 0.753，AUROC 增量为 0.087，95%置信区间为 [−0.032,0.209]，Holm 校正 p=0.629；这说明责任图对排序和证据组织有贡献，但不能据此宣称单独显著提升检测。责任图的主要目标是因果溯源和根因智能体定位，表 8 中的 RootAgent@1=0.688、@2=0.875、MRR=0.823 正是对该能力的直接评估。完整判定流程相对 L1 将 FPR 由 0.743 降至 0.057、F1 由 0.690 升至 0.852，TPR 由 1.000 降至 0.793；因此修订稿把误报改善归于完整判定流程，把责任图的核心价值表述为证据关联和根因定位。

③针对“对六维评分做逐维 leave-one-out 消融”的意见。

第 6.2.2 节开展了多组参数敏感性分析：8,103 组阈值组合的 F1 为 0.769—0.877；单维权重±20%时 F1 为 0.836—0.852；门控中心取 5—20 时 F1 为 0.830—0.852；1,000 次联合采样的 F1 中位数为 0.852，2.5%—97.5%分位区间为 [0.784,0.877]，其中 91.1%的组合不低于 0.80。结合第 6.2.1 节的五层配置消融，修订稿从组件逐步加入的整体表现和参数扰动下的结果稳定性两个方面提供了证据。逐维 leave-one-out 主要用于进一步区分单个评分维度的独立边际贡献，属于更细粒度的分析；现有层级消融与参数敏感性结果已分别回应组件贡献和整体稳健性问题，逐维分析可作为后续补充。

修改位置：第 6.2.1 节（表 9、图 6）；第 **6.2.2 节（图 7）；**第 6.1.4 节（表 8）；第 **7.3** 节。