检测流水线：从系统调用到最终判定的完整数据流（4层透视图）

第 0 层 — 原始 eBPF 事件（内核层）

process_events	file_events	ssl_events	总事件数	5 探针矩阵
进程派生/退出事件	敏感文件 OPEN 操作	TLS 加密通信明文截获	evidence → edges → nodes	sslsniff · process_new · fileaccess browsertrace · stdiocap

事件流推送至 Rust collector → ResponsibilityRuntime

第 1 层 — PBC 边界穿越门控（规则引擎）+ 6 维渐进评分

PBC (Process Boundary Crossing) 门控

N× ProcessBoundaryCrossing · FileBoundaryCrossing
NetworkBoundaryCrossing · AgentDelegatesTo
PBC total = 累计边界穿越加权值

6 维渐进评分（每 Agent · 每维度 EWMA/CUSUM 独立跟踪）

D1	边界规则	进程/文件/网络边界穿越
D2	模式匹配	子图同构 · 已知攻击模式匹配
D3	角色放大	父→多子 · 角色链深度 · 共谋环
D4	时间异常	CUSUM 漂移 · 事件密度
D5	证据质量	直接证据 vs 推断 · 证据链完整性
D6	行为密度	多进程并发敏感操作密度

EWMA α=0.10 慢速跟踪 · CUSUM h=2.5 K=3 漂移检测 · 时间衰减 300s 半衰期

6 维信号 → OWA(80%) + GeoMean(20%) → Platt 校准 → 路由决策

第 2 层 — 责任图 + 身份解析 + 污点追踪 + 传递闭包

IdentityResolver（三信号并查集）

signal_root_pid → 同 PID 树合并
signal_tls_session → 同 TLS 会话确认同源
signal_conversation_id → 同任务上下文确认
→ 结论: M 个 PID 属于同一 Agent 上下文

CausalChainTracer（因果链追溯）

目标事件 → 上游操作 → 进程派生 → 原始 LLM 响应
深度优先逆向遍历 ResponsibilityGraph 六索引结构
定位攻击根因（父 Agent 的原始 LLM 指令）
→ 因果链深度: d，根因: 父 Agent 的原始 LLM 响应

TaintTracker（三条件污点检测）

① Agent 写入共享文件 → mark_contaminated
② 另一 Agent 读取该文件 → check_access → TAINTED
③ 下游决策受污染影响 → propagate → pollution
→ 结论: C 个 contaminated artifacts · P 条污染边

传递闭包扫描 (Transitive Boundary Closure) + 祖先链构建 (build_ancestor_map)

沿进程祖先链逐级扫描每一跳的边界穿越行为，识别深度 d 处从合法行为到攻击行为的突变点
Root(PID₀) → W₁(PID₁) → W₂(PID₂) → ... → Wₙ(PIDₙ) ← 完整 N 级进程祖先链

图结构 + 身份/污点/闭包 → 融合分数

第 3 层 — 信号融合与判定（含 Observer LLM 按需仲裁）

加权融合 (OWA + GeoMean)

raw_fused = D1·0.25 + D3·0.20 + D4·0.15
+ D5·0.20 + D6·0.20

Platt 概率校准

calibrated = 1/(1+e^{-(7.0×S−3.0)})
融合 L2 证据相关性 → 校准后概率

信号增强

taint_boost: 污点传播增益
pollution_boost: 污染边放大

Observer 仲裁

按需激活
CachePrior + LLM 语义判定

最终分数 s = raw_fused + calibrated + boosts → 判定: ATTACK / BENIGN

route: unsafe_by_engine / safe_by_engine / observer_safe / observer_unsafe

S_cal ∈ [0, 1]
<0.15 → Safe (不触发)
0.15~0.70 → Grey → Observer

注：各案例的差异在于（1）第1层6维的具体分数和激活维度；（2）第2层的侧重点（身份解析/污点追踪/传递闭包）
（3）第3层 taint_boost / pollution_boost 的具体值；（4）Observer 是否被触发（仅在 grey_zone 或 evidence_conflict 时）